



Maestría en Ciencia de Datos y Gestión del Conocimiento

Asignatura: Laboratorio de Implementación III

Trabajo Final

Profesor

Denicolay, Gustavo

Alumno:

Cicconi, Carlos A.

Indice

1. Descripción del problema	3
2. Análisis Exploratorio de Datos (EDA)	4
3. Tipos de modelos ensayados	4
4. Diseño de los experimentos	5
4.1 Niveles de granularidad	5
4.2 Criterios adoptados y transformaciones hechas	5
5. Comentarios sobre los resultados	6
5.1 Media Móvil	6
5.2 Regresión Lineal	6
5.3 AutoGluon	7
5.4 LightGBM	7
6. Análisis de los Resultados	8
6.1 Selección de la predicción final	8

1. Descripción del problema

La necesidad que provoca el presente desafío es una predicción de demanda que redunde en un ajuste de los volúmenes a producir de diversos productos codificados individualmente, teniendo en cuenta los niveles de stock presentes en cada período.

La compañía que tiene esta necesidad es una empresa de carácter multinacional del rubro consumo masivo. A la misma le interesa concentrarse en la demanda de 780 productos específicos, llamados de acá en adelante "productos a predecir". Los clientes a los cuales atiende son de diversas envergaduras, desde cadenas de supermercados como Carrefour hasta distribuidores minoristas (en total hay 590 clientes).

Teniendo como dato las ventas de todos los productos de la cartera (en total son 1.233, entre los cuales están los productos a predecir) desde Enero 2017 a Diciembre 2019, la multinacional pretende hacer una predicción de las ventas para cada producto a predecir, para el mes " $n+2$ ". Esto es, si estamos actualmente parados en el mes " n ", se considera un mes de "lead time" de fabricación durante el mes " $n+1$ " para las unidades que se vayan a vender de cada producto durante el mes " $n+2$ ". Dado que el último mes del cual tenemos información es 201912, entonces el mes " $n+2$ " sería 202002 y por ende este último es el mes cuya demanda hay que predecir.

Para evaluar la calidad de la predicción la multinacional utiliza la métrica del error absoluto medio (MAE), es decir el cociente entre la suma de las diferencias entre la predicción y el valor real, y la suma de los valores reales en el mes 202002. Esto hace que sea especialmente relevante predecir con la mayor precisión posible la demanda de los productos que se llevan el grueso de las ventas (medidas en toneladas). En cuanto a la pretensión de la empresa, esta aspira a que la predicción que otorguemos no tenga un MAE superior a 0,050 (es decir, un error de no más del 5%).

2. Análisis Exploratorio de Datos (EDA)

Se realizó un Pareto tanto a nivel de producto como a nivel de cliente, el cual arrojó que el 20% de las ventas totales (medidas en Tons) se reparten en solo 10 productos de los 1.233 ítems presentes, además los 10 principales clientes consumen el 45% de las toneladas totales.

Se observó además que en el dataset existen discontinuidades, entendiéndose por esto que un determinado cliente puede no adquirir en algún mes puntual un producto que usualmente compra. De allí surge la necesidad de completar el dataset con registros con el campo $T_n = 0$ para todos los casos de compra nula de un producto por parte de un cliente en un período determinado. Esta última operación (ejecutada con la librería DuckDB de Python) hace que el dataset con granularidad período-producto-cliente crezca notablemente, de una versión original de 2.945.818 registros a 17.173.448 registros.

3. Tipos de modelos ensayados

Se probaron modelos que se pueden clasificar en estos cuatro grandes grupos:

a- **Promedio Móvil**

b- **Regresión Lineal**

c- **AutoGluon.** Este es un framework de AutoML que incluye capacidades específicas para predicción de series temporales, utilizando un enfoque de ensemble que combina múltiples modelos predictivos, tanto de la estadística clásica como de Machine Learning y Deep Learning.

d- **LightGBM** (con feature engineering y optimización de parámetros)

Para la predicción final fue seleccionado el modelo correspondiente a AutoGluon, con 2 (dos) períodos de validación (public score = 0,246).

Adicionalmente a todo esto, se aplicó también el algoritmo de Dinamic Time Warping (DTW), el cual calcula las distancias entre las series de tiempo de cada id de producto (comparándolas de a pares), y clasificando las mismas dentro de determinados grupos (clusters) por su similitud. Se utilizó un número de 50 clusters, por recomendación de la cátedra publicada en Zulip (canal "Ir3-Clase 04", tema "una muy buena solución"). Esto se usó como input para LightGBM y también para Regresión Lineal.

4. Diseño de los experimentos

4.1 Niveles de granularidad

Existen 2 (dos) niveles de granularidad de los cuales puede partir el algoritmo que determina la predicción:

- **Granularidad período-producto:** acá se suman las toneladas de cada id de producto para un mismo año-mes, sin discriminar por cliente
- **Granularidad período-producto-cliente:** se desagrega el nivel anterior a nivel de cliente, completando con 0 (cero) en los casos de que un cliente no haya comprado en un mes determinado un producto que alguna vez compró. Se tuvo en cuenta el ciclo de vida del producto, es decir, no se completó con ceros en los meses anteriores al nacimiento del mismo ni posteriores a su expiración.

En todos los modelos ensayados anteriormente, se trabajó en la granularidad más simple (período-producto), quedando pendiente hacer pruebas con la granularidad que incluye apertura por cliente.

4.2 Criterios adoptados y transformaciones hechas

Partición entrenamiento/validación: para LightGBM se dividieron los registros de la siguiente manera.

- **Entrenamiento:** desde 201701 hasta 201910
- **Validación:** desde 201911 hasta 201912

Feature Engineering: aplicado a LightGBM, se crearon las siguientes variables

- 35 lags ventas mensuales
- 34 lags de diferencias entre ventas de meses consecutivos
- Features temporales (mes, días del mes, año, quarter)
- Predicción según AutoGluon
- Cluster determinado por algoritmo de DTW (seteado para agrupar en 50 clusters)

Productos “mágicos”: por recomendación de la cátedra, se seleccionaron 33 productos con su serie completa desde 201801 hasta 201812, a los efectos de entrenar una regresión lineal con esos 12 meses para los 33 productos, estableciendo como variable target las ventas del mes 201902. Estos productos son los siguientes códigos:

[20002, 20003, 20006, 20010, 20011, 20018, 20019, 20021, 20026, 20028, 20035, 20039, 20042, 20044, 20045, 20046, 20049, 20051, 20052, 20053,

20055, 20008, 20001, 20017, 20086, 20180, 20193, 20320, 20532, 20612, 20637, 20807, 20838]

5. Comentarios sobre los resultados

5.1 Media Móvil

A modo de establecer un “baseline” para intentar superar con las predicciones posteriores, se intentó predecir 202002 promediando sucesivamente:

- Últimos 3 (tres) meses de los cuales se tiene información (201910 a 201912)
- Últimos 6 (seis) meses de los cuales se tiene información (201907 a 201912)
- Últimos 12 (doce) meses de los cuales se tiene información (201901 a 201912). Esta última fue la predicción que mejor score público registró, y por ende fue adoptada como referencia para experimentos posteriores

5.2 Regresión Lineal

Tomando los llamados 33 productos “mágicos”, se ajustó un modelo con los datos desde 201801 a 201812 y como target se utilizaron las ventas de 201902. Una vez obtenido dicho modelo, se aplicó a los datos desde 201901 a 201912 para predecir 202002, de la siguiente manera:

- Si no hay datos faltantes durante 2019, se aplica el modelo de regresión lineal obtenido
- Si por el contrario hay datos faltantes, entonces se predice 202002 como el promedio de todos los meses de 2019

Con este experimento, se mejoró el score público de la media móvil de los últimos 12 meses.

Luego se hicieron sucesivos experimentos dividiendo dichos productos “mágicos” según la clusterización resultante de aplicar DTW y ajustando un modelo de regresión lineal por cada cluster, pero los resultados no fueron satisfactorios (todos con score peor que el baseline). También se probó con incluir los productos de cada cluster que representaban el 80%-90% de las toneladas totales vendidas de ese cluster y ajustando una regresión lineal por cada cluster, pero no se llegó a superar la mencionada referencia.

5.3 AutoGluon

Se aplicó este algoritmo para todos los meses desde 201701 hasta 201912, variando la ventana de validación (se hicieron pruebas seteando esta última sucesivamente en 1, 2, 3 y 4 períodos).

El mejor resultado se correspondió con una ventana de validación de 2 (dos) períodos, los cuales serían 201911 y 201912. A su vez, se usó esta predicción de 202012 como una feature adicional para implementar LightGBM.

5.4 LightGBM

Luego de crear las nuevas features descritas anteriormente en el dataset de ventas, se hace el corte en entrenamiento y validación, y se procede siguiendo los pasos que se detallan:

- Entrenar LightGBM con X_train, y_train (hasta 201910)
- Validar con X_val, y_val (201911 + 201912 - simula predicción 3-4 meses adelante)
- Optimizar hiperparámetros usando esta división temporal (Optuna)
- Aplicar modelo final para predecir 202002
- Reentrenar incluyendo datos usados anteriormente para validación, para una mejor estimación del performance real

Rango Hiperparámetros para Optuna:

- num_leaves [10, 100]
- learning_rate [0.01, 0.3]
- feature_fraction [0.6, 1.0]
- bagging_fraction [0.6, 1.0]
- bagging_freq [1, 7]
- min_child_samples [5, 100]
- reg_alpha [0.0, 1.0]
- reg_lambda [0.0, 1.0]
- max_depth [3, 12]
- min_data_in_leaf [5, 50]

Se utilizó una sola semilla para el entrenamiento. Esto es un punto a mejorar, en cuanto a la robustez del modelo. El resultado en el score público no fue satisfactorio, es decir, no logró perforar el baseline.

6. Análisis de los Resultados

6.1 Selección de la predicción final

Para la predicción final fue seleccionado el modelo correspondiente a AutoGluon, con 2 (dos) períodos de validación (public score = 0,246). [Se puede acceder al script con este link.](#)

Este es el que mejor resultado dio en el Público, superando al Promedio Móvil y a la Regresión Lineal (esta última, entrenada con los 33 productos "mágicos"). Quedó pendiente probar ajustar el modelo de boosting (LightGBM) con un entrenamiento más largo y varias semillas para reducir la varianza.